

Análise de Grafos em uma Rede de Similaridade entre Subreddits Construída a partir de Embeddings do Reddit

Aluno Guilherme Neves

224116475

Universidade Federal da Bahia

Salvador, Bahia, Brazil

Resumo

O dataset SNAP *web-RedditEmbeddings* é analisado como uma rede de similaridade semântica entre comunidades do Reddit. Como os dados originais contêm embeddings e não uma lista explícita de arestas, o grafo é construído por vizinhos mais próximos com similaridade de cosseno sobre todos os 51.278 vetores de subreddits. O grafo simples, não direcionado e ponderado resultante tem 51.278 vértices, 446.502 arestas, densidade 0,000340, comprimento médio dos caminhos $5,7044 \pm 0,1980$ com IC 95%, clusterização média 0,2272 e 531.941 triângulos. A análise cobre métricas estruturais, algoritmos clássicos, complexidade teórica e observada, intervalos de confiança dos tempos, propriedade small-world, diagnóstico de lei de potência, robustez a remoção aleatória e ataque direcionado, descoberta principal, comparação com modelos clássicos, apêndices e instruções de reprodução. Os resultados indicam uma rede esparsa, com componente gigante, forte agrupamento local, caminhos curtos, cauda pesada de graus, tolerância a falhas aleatórias e maior sensibilidade à remoção de hubs.

CCS Concepts

• **Mathematics of computing** → **Graph algorithms**; • **Theory of computation** → **Network flows**.

Keywords

redes complexas, algoritmos de grafos, Reddit, embeddings, robustez, redes de pequeno mundo

ACM Reference Format:

Aluno Guilherme Neves. 2026. Análise de Grafos em uma Rede de Similaridade entre Subreddits Construída a partir de Embeddings do Reddit. In *Proceedings of Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia'2025)*. ACM, New York, NY, USA, 11 pages.

1 Introdução

O estudo aplica conceitos de Teoria dos Grafos e Redes Complexas a um grafo real: tratamento de dados, análise estrutural, execução de algoritmos clássicos, small-world, lei de potência, robustez e comparação com modelos clássicos. O grafo é derivado do dataset *web-RedditEmbeddings*, publicado pelo SNAP [6]. O conjunto de dados representa usuários e subreddits por embeddings temporais extraídos de interações em comunidades online [4, 5]. Como o arquivo original contém vetores e não uma lista explícita de arestas, a primeira etapa metodológica foi construir uma rede de similaridade entre comunidades.

Todos os valores numéricos apresentados no artigo foram extraídos dos artefatos do projeto na pasta `results`, incluindo JSON

de análise, CSVs de benchmarks e distribuição de graus. O código, os dados tratados, os resultados e as instruções de execução estão disponíveis no repositório: <https://github.com/guneves/TrabalhoGrafos>.

Resumo dos Resultados e Artefatos

A Tabela 1 resume os blocos principais da análise, os pontos do texto onde cada resultado aparece e os artefatos do projeto que permitem conferir os valores. A coluna “Observação” explicita quando houve estimativa por amostragem, execução em subgrafo ou conclusão conservadora.

2 Grafo Original e Determinação

O dataset oficial é *web-RedditEmbeddings*, da categoria *Online communities*, com tipo *Reddit Embeddings*. A página do SNAP informa 118.381 usuários, 51.278 subreddits, embeddings de 300 dimensões e dados extraídos de janeiro de 2014 a abril de 2017. A fonte oficial é <https://snap.stanford.edu/data/web-RedditEmbeddings.html>. Os arquivos brutos preservados localmente são:

`data/raw/web-redditEmbeddings-subreddits.csv`
`data/raw/web-redditEmbeddings-users.csv`

A matrícula utilizada é 224116475. A regra usada para determinar o grafo é

$$f(M) = ((\text{soma dos dígitos}(M)) \times (\text{últimos dois dígitos}(M) + 1)) \bmod 129.$$

O cálculo passo a passo foi:

- (1) Matrícula usada: 224116475.
- (2) Soma dos dígitos: 32.
- (3) Últimos dois dígitos: 75.
- (4) Últimos dois dígitos + 1: 76.
- (5) Multiplicação: $32 \times 76 = 2432$.
- (6) Resultado do módulo 129: $2432 \bmod 129 = 110$.
- (7) Grafo final escolhido: G110.

Assim, a matrícula determina a posição do grafo em uma lista de 129 possibilidades. Nesta análise, o grafo G110 corresponde ao dataset *web-RedditEmbeddings*.

3 Tratamento dos Dados

O SNAP disponibiliza embeddings, não uma lista pronta de arestas. Por isso, o tratamento necessário foi transformar vetores em uma rede de similaridade entre comunidades. A versão analisada é uma rede simples, não direcionada e ponderada de similaridade entre comunidades do Reddit. Cada vértice representa um subreddit; duas comunidades são conectadas quando uma aparece entre os vizinhos semanticamente mais próximos da outra. Para métricas estruturais

Tabela 1: Resumo de leitura: resultados, localização no texto e artefatos conferíveis.

Bloco	Onde conferir	Artefato conferível	Observação
Determinação do grafo	Seção 2	README.md; analysis_results.json	cálculo da matrícula até G110
Tratamento dos dados	Seção 3; Tabela 2	scripts/build_graph.py; graph_metadata.json	embeddings convertidos em grafo simples kNN
Análise estrutural	Seção 5; Tabela 3	analysis_results.json; degree_distribution.csv	medidas estruturais completas
Visualização	Figura 1	graph_visualization.png LaTeX/results	em versão reduzida para legibilidade
Algoritmos	Seção 6; Tabelas 4 e 5	scripts/analyze_graph.py; benchmark_raw_times.csv	30 execuções com média, desvio e IC 95%
Small-world	Seção 7; Apêndice A	analysis_results.json	implementado no código do projeto
Lei de potência	Seção 8; Apêndice B	degree_log_pk.png; degree_model_comparison.png	evidência sugestiva, não conclusão absoluta
Robustez	Seção 9; Apêndice C	robustness_runs.csv; robustness.png	30 repetições aleatórias e ataque por grau
Discussão e conclusão	Seções 10–12	texto do relatório	descoberta, modelos clássicos e limitações
Reprodução e checklist	Apêndices D–F	README.md; scripts do repositório	comandos de execução e checklist final

clássicas, o grafo foi considerado sem peso; para algoritmos de caminho ponderado e MST, foi usado 1 – similaridade.

Os dados tratados usados nas análises estão em `nodes.csv`, `edges.csv` e `graph_metadata.json`, na pasta `data/processed`. O README do repositório descreve como reproduzir o pipeline completo.

4 Metodologia

As métricas estruturais foram calculadas sobre a versão não ponderada quando a definição clássica depende do número de arestas. Dijkstra, Bellman-Ford, Floyd-Warshall e Kruskal usaram pesos. Diâmetro, raio e comprimento médio dos caminhos foram estimados por 16 fontes na maior componente por causa do tamanho do grafo; nessa situação, diâmetro e raio são valores observados na amostra, e o comprimento médio tem IC 95% de $\pm 0,1980$. Cada algoritmo foi executado 30 vezes. Os intervalos de confiança de 95% usam Normal/Z quando $n \geq 30$ e t-Student quando $n < 30$; nesta execução, os benchmarks usaram Normal/Z. Os tempos individuais de cada repetição foram exportados em `benchmark_raw_times.csv`, enquanto `benchmark_times.csv` contém média, desvio padrão e IC 95%; ambos ficam na pasta `results`.

Para evitar ambiguidade na correção, sempre que uma medida foi estimada ou restringida por custo computacional o texto informa a política usada. Assim, diâmetro e raio são apresentados como limites observados por amostragem, Bellman-Ford e Floyd-Warshall são marcados como execuções em subgrafos, e a lei de potência é tratada como evidência sugestiva, não como afirmação estatística definitiva.

As rotinas de grafo usadas na análise foram implementadas no próprio projeto em Python, sem bibliotecas prontas como NetworkX ou igraph. As dependências externas, como numpy, pandas e Pillow, foram usadas para vetorização, leitura de CSV e figuras, não para calcular small-world, robustez, Tarjan, Kruskal ou os percursos.

5 Análise Estrutural

A Figura 1 mostra uma amostra reduzida de 420 vértices, escolhida para tornar a estrutura legível. Os vértices azuis destacam hubs por grau e os verdes mostram vizinhos amostrados; as arestas representam relações kNN por similaridade. O bloco principal denso indica a componente gigante, enquanto o agrupamento separado evidencia que existem componentes pequenas. A figura não substitui as métricas completas, mas ajuda a ver a coexistência de alta conectividade local e hubs.

Portanto, as medidas estruturais principais foram computadas e estão presentes na Tabela 3. As ressalvas são metodológicas: diâmetro, raio e caminho médio foram obtidos por amostragem de fontes na maior componente conexa devido ao tamanho da rede, e a própria tabela informa essa condição para evitar interpretação como cálculo exato de todos os pares.

A Figura 2 apresenta o histograma de graus. O eixo vertical está em escala log10 de frequência. A maior concentração está nos graus baixos, especialmente perto do grau mínimo 10 imposto pelo kNN, e as barras diminuem rapidamente conforme o grau aumenta. A presença de poucos vértices até grau 273 indica uma cauda longa e a existência de subreddits semanticamente parecidos com muitos outros.

A Figura 3 mostra a CCDF dos graus: para cada grau k , ela indica a fração de vértices com grau maior ou igual a k . Em escala log-log, a porção central fica aproximadamente linear, sustentando a hipótese de cauda pesada. As curvaturas nas extremidades mostram que o gráfico deve ser lido como evidência visual, não como prova estatística isolada de lei de potência. O arquivo `degree_distribution.svg`, na pasta `results`, contém a mesma visualização, mantida como alias do gráfico de distribuição acumulada.

Tabela 2: Tratamento aplicado aos dados originais.

Etapa	Tratamento aplicado	Antes	Depois	Justificativa	Impacto
Fonte bruta	Download e preservação dos CSVs oficiais	2 arquivos remotos	2 arquivos em data/raw	garantir reprodutibilidade	não altera métricas
Escolha de vértices	Subreddits como vértices	118.381 usuários e 51.278 subreddits	51.278 subreddits candidatos	foco em comunidades online	usuários não entram como vértices
Uso de vértices	Todos os subreddits do CSV oficial	51.278 candidatos	51.278 vértices	usar todos os vértices disponíveis	elimina amostragem de vértices
Normalização	vetores com norma 1	embeddings de 300 dimensões	embeddings normalizados	calcular similaridade de cosseno por produto interno	prepara arestas
Construção de arestas	kNN por similaridade de cosseno	sem arestas explícitas	446.502 arestas	transformar embeddings em grafo analisável	define topologia
Simplificação	união de pares kNN em grafo simples	vizinhanças direcionais possíveis	grafo simples não direcionado	métricas exigidas assumem grafo simples	remove duplicidade de pares
Auto-loops	exclusão do próprio vértice no kNN	similaridade de cada vértice consigo mesmo	zero auto-loops	auto-loops não ajudam nas métricas exigidas	evita inflar graus e triângulos
Pesos	1 – similaridade	similaridade de cosseno	pesos não negativos	menor peso indica maior semelhança	permite Dijkstra/MST
Componentes	verificação de conectividade	grafo tratado	3 componentes; maior com 51.245 vértices	identificar a estrutura conexa usada nos caminhos	caminhos por amostragem de fontes

Tabela 3: Métricas estruturais do grafo tratado.

Medida	Valor	Computada?	Interpretação	Justificativa
Número de vértices	51.278	Sim	quantidade de subreddits usados do arquivo oficial	N/A
Número de arestas	446.502	Sim	pares de comunidades semanticamente próximas	N/A
Grau mínimo	10	Sim	efeito esperado do kNN com $k = 10$	N/A
Grau máximo	273	Sim	existe ao menos um hub semântico muito conectado	N/A
Grau médio	17,4150	Sim	rede esparsa, mas com conexões suficientes para formar uma componente gigante	N/A
Distribuição de graus	CSV gerado	Sim	cauda pesada e hubs aparecem na frequência dos graus	N/A
Densidade	0,000340	Sim	apenas pequena fração dos pares possíveis está conectada	N/A
Componentes conexas	3	Sim	há uma componente gigante e duas pequenas	N/A
Tamanho das componentes	51.245, 18, 15	Sim	a maior componente concentra quase todos os vértices, mas o grafo não é totalmente conectado	N/A
Diâmetro	13	Sim	limite inferior observado por amostragem no modo sampled	N/A
Raio	10	Sim	limite superior observado por amostragem no modo sampled	N/A
Comprimento médio	5, 7044 ± 0, 1980	Sim	poucos intermediários separam comunidades	N/A
Clusterização média	0,2272	Sim	há forte agrupamento local	N/A
Número de triângulos	531.941	Sim	muitas triplas de subreddits semanticamente próximos	N/A
Visualização	grafo reduzido	Sim	amostra visual para evitar sobreposição excessiva	N/A




Figura 1: Amostra visual da rede de similaridade entre subreddits.




Figura 2: Histograma da distribuição de graus em escala logarítmica.




Figura 3: CCDF da distribuição de graus em log-log.

6 Algoritmos Implementados

A Figura 4 usa eixo Y em log10 de segundos; por isso, diferenças pequenas na altura das barras representam ordens de grandeza. As

barras mostram a média das 30 execuções e as hastes mostram o IC 95%. A verificação de eulerianidade é muito rápida, Bellman-Ford e Floyd-Warshall ficam pequenos porque foram executados

Tabela 4: Objetivo, funcionamento e complexidade teórica dos algoritmos.

Algoritmo	Objetivo, funcionamento e condições	Complexidade
BFS	visita a origem, depois seus vizinhos, depois os vizinhos dos vizinhos; aplicável para medir alcançabilidade em grafos ponderados ou não quando o peso não importa	$O(V + E)$
DFS	explora um ramo até o fim antes de retroceder; aplicável para percorrimento e base de análises de conectividade	$O(V + E)$
Eulerianidade	checa se o grafo não direcionado é conectado e se todos os graus são pares	$O(V + E)$
Dijkstra	relaxa arestas em ordem de distância mínima por fila de prioridade; aplicável porque 1 – similaridade não é negativo	$O((V + E) \log V)$
Bellman-Ford	relaxa todas as arestas repetidamente e tolera pesos negativos; aqui é aplicável, mas redundante, pois não há pesos negativos	$O(VE)$
Floyd-Warshall	atualiza uma matriz de distâncias considerando cada vértice como intermediário; aplicável conceitualmente, mas caro no grafo completo	$O(V^3)$
Tarjan	usa tempos de descoberta e valores low-link para identificar pontos de articulação e pontes na versão não direcionada	$O(V + E)$
Kruskal/MST	ordena arestas por peso e une componentes com union-find; se o grafo for desconexo, o resultado é uma floresta geradora mínima	$O(E \log E)$

Tabela 5: Tempos observados dos algoritmos com média, desvio padrão e IC 95%.

Algoritmo	Aplicável?	Complexidade	Tempo médio (s)	Desvio padrão (s)	IC 95% (s)	Resultado
BFS	Sim	$O(V + E)$	0,093890	0,008430	$\pm 0,003017$	51.245
DFS	Sim	$O(V + E)$	0,200372	0,010345	$\pm 0,003702$	51.245
Eulerianidade	Sim	$O(V + E)$	0,000000	0,000000	$\pm 0,000000$	False
Dijkstra	Sim	$O((V + E) \log V)$	0,177694	0,006897	$\pm 0,002468$	51.245
Bellman-Ford	subgrafo	$O(VE)$	0,000005	0,000002	$\pm 0,000001$	1
Floyd-Warshall	subgrafo	$O(V^3)$	0,000256	0,000014	$\pm 0,000005$	70
Tarjan	Sim	$O(V + E)$	0,250317	0,044932	$\pm 0,016079$	5; 1
Kruskal/MST	Sim	$O(E \log E)$	0,327248	0,012688	$\pm 0,004540$	51.275




Figura 4: Tempos médios observados por algoritmo, com IC 95%.

em subgrafos, enquanto Tarjan e Kruskal aparecem entre os mais caros por percorrerem a estrutura grande do grafo.

BFS alcançou 51.245 vértices e DFS alcançou 51.245, isto é, a componente da origem usada nos testes. O grafo não é euleriano, pois nem todos os vértices têm grau par. Dijkstra alcançou 51.245 vértices com pesos não negativos. Bellman-Ford foi executado em

Tabela 6: Comparação small-world com grafos aleatórios equivalentes.

Métrica	Grafo real	Aleatórios	Comparação
Comprimento médio	5,7044	$4,0575 \pm 0,0314$	mesma ordem
Clusterização média	0,2272	$0,0003 \pm 0,0000$	real 661,63 vezes maior

subgrafo de 120 vértices e Floyd-Warshall em subgrafo de 70 vértices, com justificativa técnica de custo. Tarjan encontrou 5 pontos de articulação e 1 ponte. Kruskal gerou uma floresta geradora mínima com 51.275 arestas e peso total 3127,7570.

7 Análise de Small-World

A análise verifica se o grafo apresenta indícios de propriedade small-world, se essa interpretação faz sentido para a rede e qual é sua implicação prática.

Há indícios relevantes, de moderados a fortes, de small-world no sentido clássico de Watts e Strogatz [7]. O comprimento médio dos caminhos permanece pequeno em termos práticos e da

Tabela 7: Amostra da tabela de $P(k)$ usada no gráfico log-log.

k	Freq.	$P(k)$	$\log(k)$	$\log(P(k))$
10	7753	0,151195	2,3026	-1,8892
11	5972	0,116463	2,3979	-2,1502
12	4818	0,093958	2,4849	-2,3649
13	4240	0,082687	2,5649	-2,4927
14	3580	0,069816	2,6391	-2,6619
15	3041	0,059304	2,7081	-2,8251
16	2654	0,051757	2,7726	-2,9612
17	2269	0,044249	2,8332	-3,1179
18	1976	0,038535	2,8904	-3,2562
19	1687	0,032899	2,9444	-3,4143
273	1	0,000020	5,6095	-10,8450

mesma ordem do aleatório, embora seja maior que o do grafo aleatório equivalente; ao mesmo tempo, a clusterização real é muito maior. Isso faz sentido para subreddits, pois comunidades temáticas formam grupos locais densos, mas ainda se conectam por caminhos curtos via interesses intermediários. A implicação prática é comunicação ou propagação eficiente entre comunidades com forte agrupamento local. O cálculo foi feito com BFS, contagem de triângulos/clusterização e grafos aleatórios implementados no script `scripts/analyze_graph.py`, evitando bibliotecas prontas de análise de redes.



8 Análise de Lei de Potência

A distribuição de graus foi analisada para verificar se há indícios de lei de potência. A distribuição sugere cauda pesada e presença de hubs, mas não permite afirmar rigorosamente uma lei de potência sem teste estatístico completo, seguindo a cautela metodológica recomendada por Clauset et al. [2]. A CCDF em escala log-log teve inclinação estimada 3,4808 e $R^2 = 0,9867$. Como melhoria, também foi aplicado um ajuste discreto exploratório por máxima verossimilhança: $\alpha = 4,6905$, $x_{\min} = 42$, cauda com 1.454 vértices (2,84%) e KS = 0,0118. A cauda ajustada favoreceu lei de potência sobre exponencial no diagnóstico exploratório de log-verossimilhança.

A Figura 5 usa a probabilidade pontual de cada grau, não a probabilidade acumulada. A tendência decrescente quase linear reforça a presença de cauda pesada, mas os pontos dos graus altos ficam ruidosos porque há poucos vértices em cada grau extremo. Portanto, ela é útil como evidência visual complementar a CCDF e ao ajuste MLE.

A Figura 6 compara a distribuição observada com uma Poisson de média igual ao grau médio e uma normal com a mesma média e desvio padrão dos graus observados. Como o eixo Y está em $\log_{10}$, probabilidades visualmente nulas usam um piso numérico apenas para renderização. A curva observada mantém probabilidade visível por uma faixa muito maior de graus do que Poisson e normal com média comparável. As distribuições homogêneas concentram massa perto da média, enquanto o grafo real preserva vértices raros de grau muito alto.

Portanto, há muitos vértices em graus baixos ou moderados, e poucos vértices de grau muito alto, como o grau máximo 273, muito acima do grau médio 17,4150. Há indícios compatíveis com lei de

**Figura 5: Gráfico de $\log(P(k))$ versus $\log(k)$.****Figura 6: Comparação de $P(k)$ observada com Poisson e normal.**

potência e rede parcialmente livre de escala, mas a evidência é sugestiva, não conclusiva.

9 Análise de Robustez

A robustez do grafo foi avaliada por remoção aleatória de 5% dos vértices e pela remoção dos 5% mais centrais. Foram removidos 2.564 vértices, equivalentes a 5% da rede tratada. A remoção aleatória foi repetida 30 vezes; o ataque direcionado removeu os 5% de maior grau. Como a remoção pode fragmentar a rede, o comprimento médio dos caminhos foi calculado na maior componente conexa remanescente e estimado por amostragem de fontes.

A Figura 7 resume os ensaios de robustez. As caixas azuis mostram as 30 remoções aleatórias de 5% dos vértices, enquanto o ponto vermelho mostra o ataque por grau. A remoção aleatória quase não muda a maior componente e mantém poucas componentes. O ataque direcionado fica claramente pior no número de componentes, na fração isolada e no comprimento médio, mostrando que os hubs são importantes para encurtar caminhos e reduzir fragmentação.

O grafo é muito robusto a falhas aleatórias, pois a maior componente reteve em média 99,93% dos vértices restantes. A remoção dos 5% vértices de maior grau é mais danosa: fragmenta a rede em 42 componentes, gera nós isolados e aumenta o comprimento

Tabela 8: Robustez após remoção de 5% dos vértices.

Métrica	Original	Remoção aleatória 5%	Remoção dos 5% mais cen- trais	Interpretação
Maior componente	51.278	48680, 6000 ± 1, 6482	48.641	ataque central reduz mais a componente principal
Número de componentes	3	3, 1667 ± 0, 1356	42	ataque central fragmenta a rede
Comprimento médio	5,7044	5, 9922 ± 0, 0706	6,3694	caminhos crescem mais no ataque central
Fração de nós isolados	0	0, 0000 ± 0, 0000	0,0008	ataque central gera isolados




Figura 7: Boxplots de robustez para remoção aleatória e ataque por grau.

médio dos caminhos. Portanto, há vulnerabilidade maior a ataques direcionados do que a falhas aleatórias.

10 Principal Constatação Empírica

A principal constatação empírica é que a rede de subreddits é altamente agrupada e, ao mesmo tempo, redundante. Esse padrão aparece no clustering médio 0,2272, nos 531.941 triângulos e no resultado de Tarjan: 5 pontos de articulação e 1 ponte. Em termos práticos, comunidades semanticamente próximas não dependem de uma única rota: mesmo quando hubs são removidos, a maior componente ainda retém 99,85% dos vértices restantes, embora o ataque tenha aumentado a fragmentação e o caminho médio.

11 Comparação com Modelos Clássicos

O grafo foi comparado com os modelos clássicos Erdős-Rényi, Barabási-Albert e Watts-Strogatz [1, 3, 7].

Tabela 9: Comparação qualitativa com modelos clássicos.

Modelo	Evidências principais	Aproximação
Erdős-Rényi	explica apenas esparsidade e componente gigante; falha em clusterização e grau máximo.	fraca
Barabási-Albert	captura hubs, cauda pesada e maior vulnerabilidade a ataque central, mas não o alto agrupamento local.	parcial
Watts-Strogatz	combina alto clustering e caminhos curtos, que são os sinais empíricos mais fortes da rede.	mais próximo

A aproximação mais forte é com Watts-Strogatz/small-world, com traços parciais de Barabási-Albert por causa dos hubs. A aproximação com Erdős-Rényi é fraca, porque a clusterização real é muito maior que a esperada em um grafo aleatório homogêneo. Como as arestas foram criadas por similaridade semântica entre embeddings, nenhum modelo clássico descreve completamente o mecanismo de formação do grafo.

12 Discussão Crítica

O resultado depende da escolha de k . Como todos os subreddits disponíveis são usados, não há amostragem de vértices; ainda assim, como o dataset original é embedding, qualquer grafo derivado exige uma regra metodológica de criação de arestas. Valores maiores de k aumentariam densidade e poderiam reduzir diâmetro; valores menores poderiam fragmentar a rede.

Bellman-Ford e Floyd-Warshall foram executados em subgrafos por custo computacional, portanto seus tempos medem a implementação e a aplicabilidade conceitual, não o custo do grafo completo. A análise de lei de potência combina diagnóstico visual e ajuste MLE discreto exploratório, mas ainda não substitui um estudo estatístico completo com bootstrap de p-valor e comparações formais adicionais.

13 Conclusão

A análise aplicou tratamento de dados, construção de grafo, análise estrutural, algoritmos clássicos, small-world, lei de potência e robustez ao dataset *web-RedditEmbeddings*. A rede tratada é dominada por uma componente gigante, pouco densa, altamente clusterizada, robusta a falhas aleatórias e mais sensível à remoção de hubs semânticos. A principal descoberta foi que a rede combina redundância local, refletida por 531.941 triângulos e clusterização 0,2272, com poucos pontos estruturais realmente críticos: Tarjan encontrou 5 pontos de articulação e 1 ponte.

Acknowledgments

A elaboração do artigo utilizou os artefatos computacionais gerados no repositório do projeto.

Referências

- [1] Albert-Laszlo Barabasi and Reka Albert. 1999. Emergence of Scaling in Random Networks. *Science* 286, 5439 (1999), 509–512.
- [2] Aaron Clauset, Cosma Rohilla Shalizi, and Mark E. J. Newman. 2009. Power-Law Distributions in Empirical Data. *SIAM Rev.* 51, 4 (2009), 661–703.
- [3] Paul Erdos and Alfred Renyi. 1959. On Random Graphs I. *Publicationes Mathematicae* 6 (1959), 290–297.
- [4] Srijan Kumar, William L. Hamilton, Jure Leskovec, and Dan Jurafsky. 2018. Community Interaction and Conflict on the Web. In *Proceedings of the 2018 World Wide Web Conference*. International World Wide Web Conferences Steering Committee, 933–943.
- [5] Srijan Kumar, Xikun Zhang, and Jure Leskovec. 2019. Predicting Dynamic Embedding Trajectory in Temporal Interaction Networks. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 1269–1278.
- [6] Stanford Network Analysis Project. 2019. Reddit User and Subreddit Embeddings. <https://snap.stanford.edu/data/web-RedditEmbeddings.html>. Accessed: 2026-06-18.
- [7] Duncan J. Watts and Steven H. Strogatz. 1998. Collective Dynamics of Small-World Networks. *Nature* 393, 6684 (1998), 440–442.

A Small-World

A definição operacional de pequeno mundo foi baseada nas leituras: https://en.wikipedia.org/wiki/Small-world_network e https://pt.wikipedia.org/wiki/Redes_de_pequeno_mundo. Uma rede possui propriedade small-world quando a distância média entre vértices é pequena e o coeficiente de clusterização é alto. Formalmente, a comparação adotada na análise foi:

$$L(G) \approx L_{\text{aleatório}} \quad \text{e} \quad C(G) \gg C_{\text{aleatório}}.$$

No grafo tratado, a conclusão aparece na Tabela 6: o comprimento médio está na mesma ordem de grandeza do aleatório equivalente, enquanto a clusterização é centenas de vezes maior.

B Lei de Potência

A definição de lei de potência foi baseada em https://en.wikipedia.org/wiki/Power_law. A hipótese investigada é se a probabilidade de um vértice ter grau k segue aproximadamente

$$P(k) \sim Ck^{-\gamma},$$

com $\gamma > 1$. A intuição é que, em uma rede com lei de potência, muitos vértices têm grau pequeno e poucos vértices funcionam como hubs de grau muito alto. Para verificar isso, a rotina computacional calcula a distribuição de graus, gera histograma, CCDF e o gráfico $\log(P(k))$ versus $\log(k)$. A análise da Seção 8 também inclui um ajuste exploratório por máxima verossimilhança e comparação visual com Poisson e normal.

C Robustez

O procedimento de robustez mediu o efeito da remoção de 5% dos vértices. Como o grafo original já tem 3 componentes, as distâncias após remoção foram calculadas na maior componente conexa remanescente. Foram medidas quatro grandezas: tamanho da maior componente, número de componentes, distância média e fração de vértices isolados.

Para a remoção aleatória, foram executadas 30 repetições, removendo vértices uniformemente ao acaso e reportando média, desvio padrão e IC 95%. Para o ataque direcionado, a centralidade escolhida foi grau, porque remove diretamente os hubs da rede. O ranking é fixo: calcula-se o grau no grafo original, ordenam-se os vértices do maior para o menor grau, removem-se os 5% mais centrais e recalculam-se as mesmas métricas. A comparação aparece na Seção 9.

D Código Principal

O código completo está organizado em scripts reprodutíveis. O repositório da entrega é <https://github.com/guneves/TrabalhoGrafos>. Os scripts principais são:

- `scripts/download_data.py`: baixa os CSVs oficiais.
- `scripts/build_graph.py`: lê embeddings, normaliza vetores, constrói kNN, salva vértices/arestas e visualização.
- `scripts/analyze_graph.py`: calcula métricas, algoritmos, tempos, small-world com grafos aleatórios, lei de potência com MLE exploratório e robustez.

E Como Reproduzir

Pipeline detalhado:

```
pip install -r requirements.txt
python scripts/download_data.py
python scripts/build_graph.py --k 10
python scripts/analyze_graph.py --benchmark-runs 30 \
    --robustness-runs 30 \
    --path-samples 16 \
    --random-graphs 5
Atalho equivalente:
python main.py
```

Tabela 10: Checklist final de cobertura da análise.

Item	Atendido?	Onde aparece
Calculo do grafo pela matrícula	Sim	Seção 2
Tratamento dos dados informado	Sim	Seção 3
Número de vértices e arestas	Sim	Seção 5
Grau mínimo, máximo e médio	Sim	Seção 5
Distribuição de graus	Sim	Seções 5 e 8; gráficos de graus
Densidade	Sim	Seção 5
Componentes conexas e tamanhos	Sim	Seção 5
Diâmetro, raio e caminho médio	Sim	Seção 5
Clusterização média e triângulos	Sim	Seção 5
Visualização do grafo	Sim	Figura 1
BFS, DFS, Eulerianidade, Dijkstra, Bellman-Ford, Floyd-Warshall, Tarjan e Kruskal	Sim	Seção 6
Complexidade teórica, tempo real, média, desvio padrão e IC	Sim	Seção 6
Small-world	Sim	Seção 7
Lei de potência	Sim	Seção 8
Robustez aleatória e por centralidade	Sim	Seção 9
Principal constatacao empirica	Sim	Seção 10
Comparação com modelos clássicos	Sim	Seção 11
Apêndices Small-world, lei de potência e robustez	Sim	Apêndices A, B e C
Link GitHub, código e README	Sim	Seções 1, D e E